Projeto M2 – Segmentação e Morfologia

Universidade do Vale do Itajaí (UNIVALI)
Curso: Ciência da Computação — Disciplina: Processamento de Imagens
Professor: Felipe Viel

Autores:
Hugo Bertoglio
Fabricio Prebianca
João Victor Guero

Novembro de 2026

1. Enunciado, Contexto da Aplicação e Objetivo

Neste trabalho, usamos segmentação para separar maçãs do fundo e identificar regiões com cor de pele. Essas tarefas aparecem em aplicações como contagem de frutas e localização de possíveis faces. Nas imagens usadas, os principais obstáculos são sombras, reflexos e cores semelhantes entre o objeto e o fundo.

O trabalho reúne os dois projetos de segmentação do enunciado. Para a morfologia, escolhemos a Opção 1, aplicada às maçãs:

• Projeto 1 (Segmentação por K-means): Agrupamento das imagens de maçãs no espaço de cores 3D (RGB) e no espaço 5D (RGB + coordenadas X e Y), incluindo o gráfico de dispersão 3D para a imagem 2or4objects.jpg.

• Morfologia Matemática (Opção 1 – Maçãs): Conversão dos grupos do K-means em máscaras binárias e aplicação de erosão, dilatação, abertura e fechamento implementados do zero para avaliar se o pós-processamento reduz as diferenças entre RGB e RGB+XY.

• Projeto 2 (Detecção de pele e face from scratch): Comparação entre limiarização de cor em RGB e HSV (baseada em Kolkur et al., 2017) e segmentação semeada por crescimento de regiões (Region Growing), além da discussão sobre métricas de avaliação sem Deep Learning.

Usamos as imagens da disciplina: 2apples.jpg, 2or4objects.jpg e 7apples.jpg para maçãs; face1.jpg, face2.jpg, face3.jpeg e face4.jpg para rostos; e colors.jpg e variableObjects.jpeg como testes extras. Reduzimos o maior lado para até 300 pixels, mantendo a proporção, para diminuir o tempo de execução. Essa redução pode apagar detalhes finos. Usamos NumPy nos cálculos, Pillow na leitura e no redimensionamento, Matplotlib nos gráficos e pathlib e collections.deque da biblioteca padrão. Os algoritmos estão implementados no notebook, sem detectores prontos.

2. Segmentação das Maçãs com K-means (RGB vs. RGB+XY)

O K-means alterna a atribuição dos pixels ao centro mais próximo e o cálculo da média de cada grupo, buscando reduzir a soma das distâncias quadradas. No RGB, cada pixel tem três valores de cor. No RGB+XY, acrescentamos a coluna X e a linha Y. Normalizamos cores e coordenadas entre 0 e 1 e aplicamos peso 0,3 à posição nos testes principais:

```
dados = [R/255, G/255, B/255, 0.3 * X/max(largura-1, 1), 0.3 * Y/max(altura-1, 1)]
```

Usamos K=4 em 2apples e 2or4objects e K=8 em 7apples, considerando as frutas e as diferenças de cor do fundo, das sombras e dos reflexos. Isso não significa um grupo por maçã. Depois do agrupamento, examinamos cada grupo e juntamos os que representam as frutas para formar as máscaras binárias.

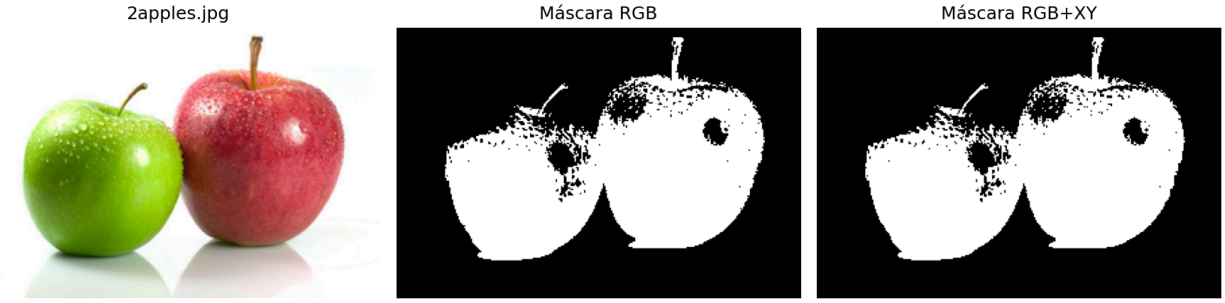

Figura 1. 2apples.jpg: imagem original, máscara obtida com K-means RGB e máscara com K-means RGB+XY.

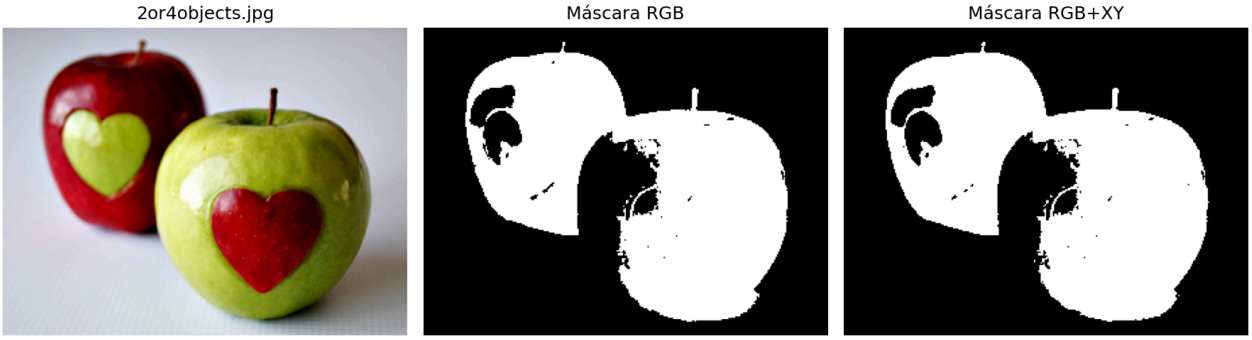

Figura 2. 2or4objects.jpg: original e máscaras binárias. Cada maçã tem partes vermelhas e verdes na mesma fruta.

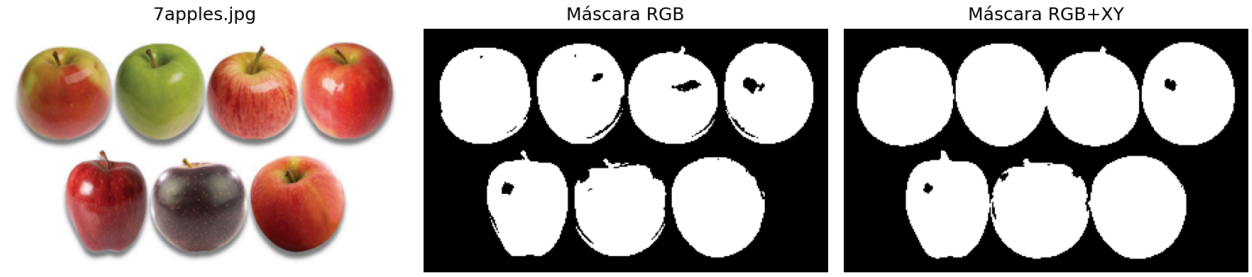

Figura 3. 7apples.jpg: original e máscaras binárias obtidas com K=8.

Em 2apples (Figura 1), partes claras das frutas são excluídas junto com o fundo, deixando falhas nas máscaras. Em 2or4objects (Figura 2), sombras e reflexos dificultam a seleção dos grupos. Em 7apples (Figura 3), RGB+XY preenche algumas falhas, mas também aproxima ou conecta regiões vizinhas. Uma máscara mais preenchida, portanto, não é necessariamente mais correta.

3. Efeito do Valor de K, do Peso Espacial e Dispersão 3D

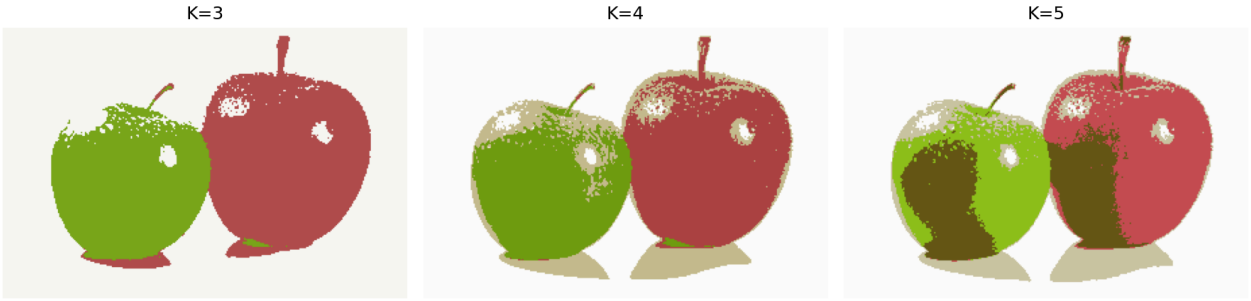

Figura 4. Efeito da variação de K (K=3, K=4 e K=5) apenas com cor RGB em 2apples.jpg.

Na Figura 4, mudar K de 3 para 4 e 5 altera a divisão entre fruta, sombra, fundo e reflexos. Aumentar K permite separar mais tons, mas também subdivide uma mesma maçã. Por isso, mais grupos não significam necessariamente uma segmentação melhor.

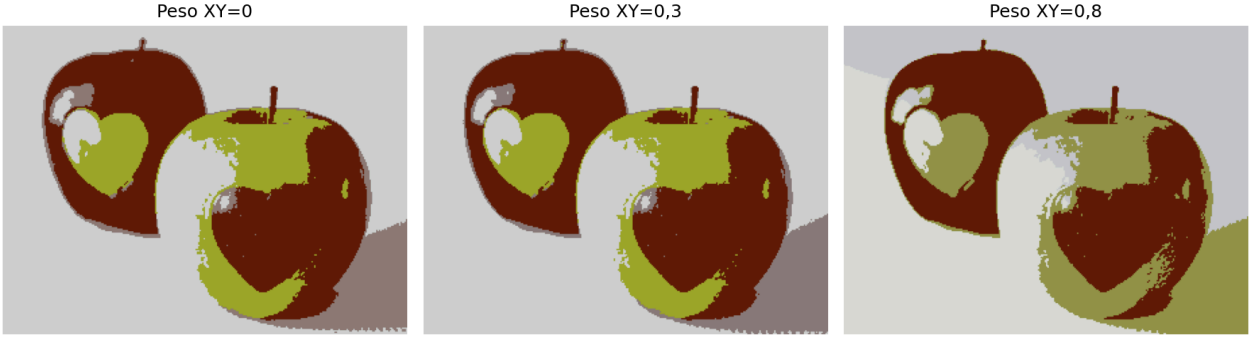

Figura 5. Efeito do peso espacial XY (0, 0,3 e 0,8) mantendo K=4 em 2or4objects.jpg.

Com peso XY=0, o agrupamento considera apenas RGB. Ao aumentar o peso para 0,8 (Figura 5), a sombra no canto inferior direito passa a compartilhar a cor reconstruída de um grupo da fruta. A posição altera os grupos, mas também pode incluir fundo junto ao objeto. Como esse teste mostra reconstruções, seria preciso selecionar novamente os grupos para obter máscaras em cada peso.

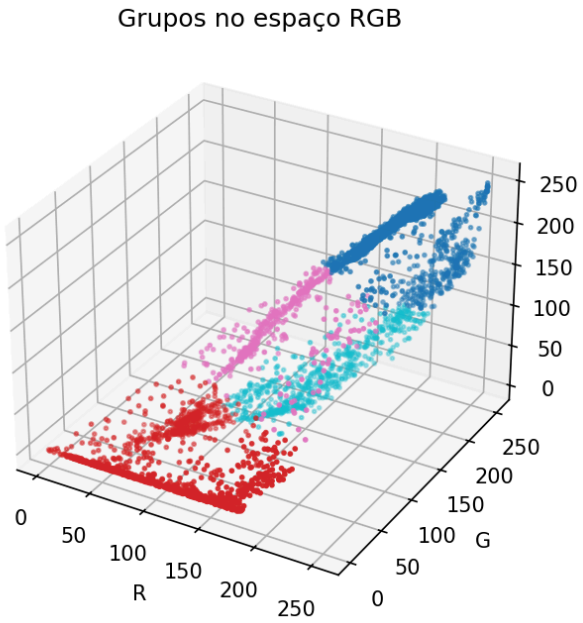

Figura 6. Gráfico de dispersão 3D no espaço RGB para 2or4objects.jpg (amostra de 5.000 pixels).

Na dispersão 3D (Figura 6), pixels de cores próximas ficam juntos mesmo quando pertencem a maçãs diferentes. As variações de brilho espalham os pontos, enquanto o fundo claro aparece com valores altos nos três canais. O gráfico ajuda a entender por que agrupar cores não basta para separar cada fruta.

4. Morfologia Matemática nas Máscaras das Maçãs (Opção 1)

Usamos um elemento estruturante quadrado, com tamanhos 3x3 e 7x7. Na erosão, o pixel permanece branco apenas se toda a vizinhança for branca; na dilatação, basta um pixel branco na vizinhança. A abertura faz erosão seguida de dilatação e remove estruturas pequenas. O fechamento inverte essa ordem e preenche pequenas falhas. O efeito depende do tamanho do elemento: essas operações não recuperam exatamente o contorno original. Fora da imagem, o código considera fundo.

Figura 7. Efeito individual da erosão 3x3 e da dilatação 3x3 sobre a máscara RGB de 2apples.jpg.

Figura 8. Efeito da abertura 3x3 e do fechamento 3x3 sobre a mesma máscara de 2apples.jpg.

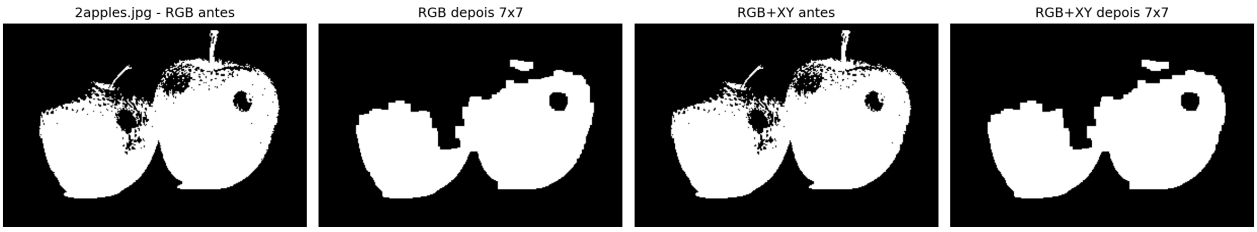

Figura 9. Comparação em 2apples.jpg antes e depois de abertura + fechamento com elemento 7x7.

Aplicamos abertura seguida de fechamento às máscaras RGB e RGB+XY, com elementos 3x3 e 7x7. A tabela mostra a porcentagem de pixels diferentes entre os métodos antes e depois:

Imagem	Elemento	Diferença antes (%)	Diferença depois (%)
2apples.jpg	3x3	0,16	0,18
2apples.jpg	7x7	0,16	0,27
2or4objects.jpg	3x3	0,31	0,31
2or4objects.jpg	7x7	0,31	0,24
7apples.jpg	3x3	4,06	4,53
7apples.jpg	7x7	4,06	4,44

1) A morfologia reduz as diferenças entre RGB e RGB+XY? Nem sempre. Em 2or4objects com 7x7, a diferença caiu de 0,31% para 0,24%. Em 7apples, subiu de 4,06% para 4,44% com 7x7 e para 4,53% com 3x3. Em 2apples também aumentou. As operações alteram as duas máscaras de maneira diferente; esses valores indicam semelhança entre métodos, não acerto.

2) Quando a morfologia melhora ou prejudica a separação? A abertura ajuda a remover pontos isolados, e o fechamento pode preencher pequenas falhas. Porém, em 7apples, o elemento 7x7 criou pontes entre frutas próximas. A abertura também pode apagar detalhes finos. O tamanho do elemento precisa considerar tanto a escala das maçãs quanto a distância entre elas.

5. Detecção de Pele por Limiarização: RGB vs. HSV

Implementamos a conversão HSV e a limiarização usando os intervalos da página 5 de Kolkur et al. (2017). Em RGB: R > 95, G > 40, B > 20, R > G, R > B e |R - G| > 15. Em HSV: 0° <= H <= 50° e 0,23 <= S <= 0,68. O artigo combina RGB, HSV e YCbCr; aqui comparamos RGB e HSV separadamente, como pede o enunciado. As imagens são convertidas para RGB, sem canal alfa. Portanto, usamos os limiares como referência, sem reproduzir o classificador completo do artigo.

Figura 10. face2.jpg: comparação entre a limiarização em RGB e em HSV.

Figura 11. face3.jpeg: caso em que o fundo possui tonalidade muito próxima à da pele.

Em face2 (Figura 10), HSV cobre mais regiões da face que RGB, mas também aceita pontos no cabelo. Separar matiz e saturação do brilho V pode ajudar sob variações de intensidade, mas não elimina os efeitos da iluminação. A comparação visual não permite atribuir todas as falhas do RGB a um único limiar.

Em face3 (Figura 11), RGB marca 73,77% da imagem e HSV, 89,79%. Ambos incluem bastante fundo e nenhum isola o rosto. O fundo tem cores semelhantes às da pele, o que dificulta a limiarização. Assim, nos exemplos avaliados, HSV cobre mais áreas da face em face2, mas também aceita mais fundo em face3. Não há um método melhor em todos os casos, e as porcentagens de área não medem acurácia.

6. Segmentação Semeada (Crescimento de Regiões)

Escolhemos manualmente uma semente na face, em coordenadas (Y, X) da imagem reduzida. A partir dela, uma fila percorre os quatro vizinhos de cada pixel aceito. O candidato entra na região se sua distância Euclidiana até a média RGB atual for menor ou igual à tolerância. A expansão é iterativa, sem chamadas recursivas. Cada candidato é avaliado uma vez; como os rejeitados não são reconsiderados quando a média muda, a ordem de visita influencia o resultado.

```
media = soma_das_cores / quantidade
distancia = norm(cor_do_vizinho - media)
if distancia <= tolerancia: aceitar_pixel
```

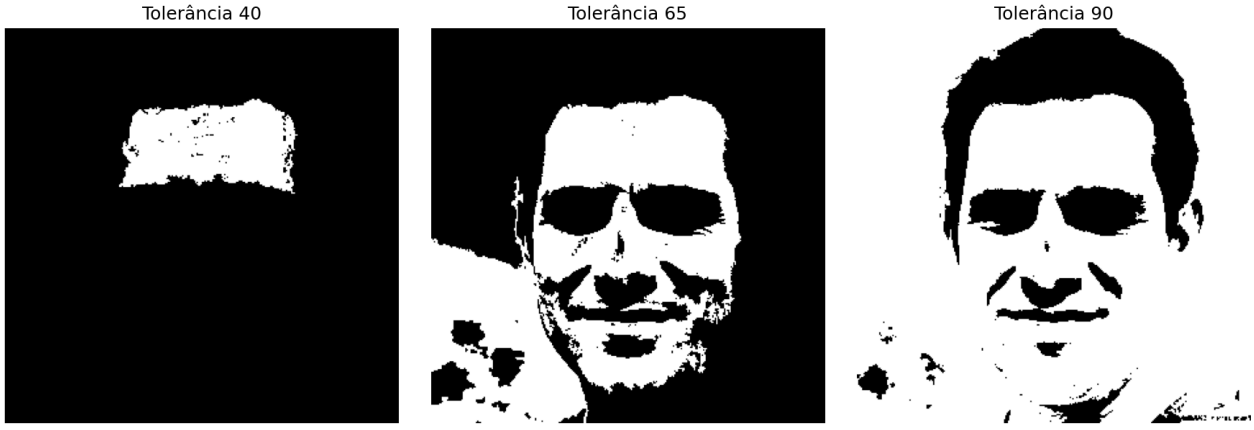

Figura 12. face1.jpg: crescimento de regiões com tolerâncias 40, 65 e 90 a partir da mesma semente.

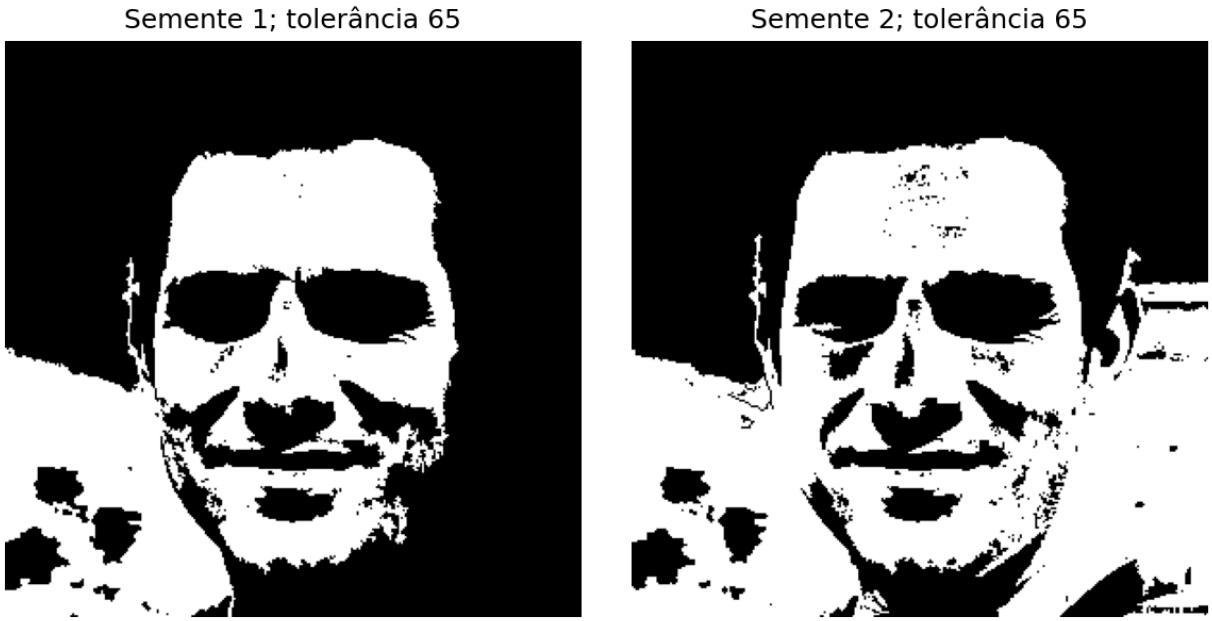

Figura 13. face1.jpg: efeito da mudança do ponto de semente mantendo a tolerância 65.

Imagem	Tol. 40: área (%)	Tol. 65: área (%)	Tol. 90: área (%)
face1.jpg	7,80	33,74	78,56
face2.jpg	2,74	8,78	28,48
face3.jpeg	16,22	35,63	70,65
face4.jpg	2,75	13,83	37,08

O crescimento forma uma região conectada à semente. Em face1, as três tolerâncias mostram como esse critério afeta a expansão:

• Tolerância 40: a região fica concentrada na testa, ocupando 7,80% da imagem. O limite é baixo para atravessar as variações de cor ao redor dessa região.

• Tolerância 65: a região se expande por boa parte da face e ocupa 33,74% da imagem, ainda com falhas internas.

• Tolerância 90: a região alcança o fundo e ocupa 78,56% de face1. Em face3, chega a 70,65%. A tolerância maior aceita mais variações, e os novos pixels também alteram a média usada nas próximas comparações.

7. Discussão sobre Métricas de Avaliação e Conclusão

IoU, Dice, precisão e recall podem avaliar a segmentação mesmo sem Deep Learning. IoU é a interseção entre a máscara obtida e a referência dividida pela união. Dice mede a sobreposição com peso duplo para a interseção. Precisão indica quanto do que foi marcado pertence ao alvo; recall indica quanto do alvo foi encontrado. Assim, fundo marcado por engano reduz a precisão, enquanto partes do alvo não detectadas reduzem o recall.

Essas métricas precisam de máscaras de referência, que não estão nos arquivos locais do trabalho. Por isso, usamos inspeção visual, área marcada e diferença entre máscaras, sem tratá-las como taxas de acerto. Uma avaliação futura também precisaria definir o alvo: toda a pele visível ou apenas a face, pois isso muda a classificação de regiões como o pescoço.

Os testes mostraram limites diferentes em cada método. No K-means, acrescentar XY mudou os grupos, mas não garantiu melhor separação. A morfologia corrigiu pequenas falhas, porém o elemento 7x7 uniu maçãs próximas. Nos rostos, RGB e HSV confundiram pele e fundo, enquanto o crescimento dependeu bastante da semente e da tolerância. Para essas imagens, ajustar os parâmetros exige observar quais partes do alvo foram recuperadas e quais regiões indevidas entraram na máscara.

Referências

VIEL, Felipe. Projeto M2 - Segmentação e Morfologia. Enunciado e material da disciplina de Processamento de Imagens, UNIVALI, 2026.

VIEL, Felipe. Repositório ColabProjects (dataset/ImgSegTrab). Disponível em: https://github.com/VielF/ColabProjects/tree/0aa1646a18c9706e04a44393accb8031c170c54a/dataset/ImgSegTrab.

KOLKUR, S. et al. Human Skin Detection Using RGB, HSV and YCbCr Color Models. arXiv:1708.02694, 2017.